

Decisão final

Escolha do modelo principal para previsão de recorrência de fibrilhação auricular após ablação, usando dados estritamente pré-operatórios.

Projeto PIC - V16 | Documento gerado em 23/05/2026 a partir dos outputs atuais da pasta ML v16.

Recomendação. Usar o BernoulliNB tuned como modelo principal do trabalho, mantendo o ExtraTrees tuned como análise complementar/sensibilidade e o GNB fixed como baseline conservador e interpretável.

Resumo executivo

A comparação final entre GNB fixed, BernoulliNB tuned e ExtraTrees tuned mostra que o ExtraTrees tuned tem a maior AUC LOOCV nominal. No entanto, a diferença para o BernoulliNB tuned é pequena e, no threshold 0.50, o BernoulliNB apresenta um perfil clínico mais equilibrado: melhor Average Precision, melhor F1 e maior sensibilidade.

Por isso, a decisão científica mais defensável não é escolher automaticamente o modelo com maior AUC pontual. A decisão recomendada é escolher o modelo que combina discriminação, simplicidade, estabilidade metodológica, rastreabilidade e menor risco de parecer otimizado a posteriori num dataset pequeno.

Critério de decisão

- Objetivo primário: previsão pré-operatória, sem blanking_period como variável de entrada.
- Validação principal: LOOCV com seleção ANOVA feita dentro do fold, sem usar o paciente de teste.
- Hyperparameter tuning: aceitável quando feito dentro do ciclo de treino/validação e não sobre o teste.
- Métrica principal: AUC LOOCV, complementada por Average Precision, Brier score e matriz de confusão.
- Critério clínico: atenção aos falsos negativos, porque todos os modelos ainda falham uma fração relevante dos doentes com recorrência.

Resultados principais sem blanking period

A tabela seguinte resume a avaliação pré-operatória principal. Estes são os resultados a usar para comparar os modelos no objetivo real do projeto.

Modelo	k	AUC LOOCV	Average Precision	Brier	Sens.	Spec.	F1

GNB fixed	18	0.702	0.528	0.273	0.423	0.879	0.512
BernoulliNB tuned	18	0.726	0.602	0.210	0.481	0.838	0.538
ExtraTrees tuned	12	0.734	0.510	0.201	0.385	0.828	0.449

Fonte: results_comp_modelos/final_options/v16_3_final_options_summary.csv, v16_3_final_options_diagnostic_overlay_summary.csv e v16_confusion_matrix_metrics_summary.csv.

Leitura dos resultados

- ExtraTrees tuned é o melhor se a decisão for baseada apenas na AUC nominal: 0.734.
- BernoulliNB tuned é praticamente equivalente em AUC: 0.726, mas tem melhor Average Precision, maior sensibilidade e melhor F1 no threshold 0.50.
- GNB fixed continua útil como baseline simples: tem a maior especificidade e permite mostrar que o sinal preditivo não depende de um modelo complexo.

Matriz de confusão no threshold 0.50

Modelo	TN	FP	FN	TP	Accuracy	Sens.	Spec.	NPV
GNB fixed	87	12	30	22	0.722	0.423	0.879	0.744
BernoulliNB tuned	83	16	27	25	0.715	0.481	0.838	0.755
ExtraTrees tuned	82	17	32	20	0.675	0.385	0.828	0.719

Threshold 0.50. A otimização de threshold pode alterar sensibilidade, especificidade, PPV, NPV e F1, mas não altera a AUC.

Porque o ExtraTrees não deve ser o modelo principal

O ExtraTrees não é um mau modelo. Na verdade, neste V16 foi o melhor por AUC nominal. O ponto é mais fino: neste dataset específico, não é o modelo mais defensável como escolha principal. A literatura sobre modelos preditivos clínicos, datasets pequenos e algoritmos de árvores dá quatro razões para esta cautela.

1. Dataset pequeno e razão eventos/complexidade desfavorável

O dataset tem 151 doentes e 52 recorrências. Mesmo com seleção ANOVA para k=12 no ExtraTrees, cada árvore constrói divisões sucessivas em subconjuntos muito pequenos de pacientes. Em modelos clínicos, amostras pequenas aumentam a instabilidade das estimativas, o risco de overfitting e a incerteza das métricas de performance. Isto é especialmente importante quando se compara uma diferença de AUC de apenas 0.008 face ao BernoulliNB.

2. Árvores são modelos de alta variância

Árvores de decisão são conhecidas por serem sensíveis a pequenas alterações nos dados de treino. Ensembles como Random Forests e ExtraTrees reduzem essa variância por agregação, mas não eliminam o problema quando o número de eventos é baixo e as features têm ruído. No nosso caso, isto aparece

de forma prática: o ExtraTrees tem maior AUC global, mas pior sensibilidade, pior F1 e mais falsos negativos no threshold 0.50 do que o BernoulliNB.

3. Randomização adicional aumenta robustez, mas também pode aumentar viés

O ExtraTrees foi desenhado para introduzir mais aleatoriedade do que uma Random Forest clássica, escolhendo divisões de forma extremamente randomizada. Esta estratégia pode reduzir variância por decorrelação entre árvores, mas pode aumentar viés. Em datasets pequenos, este equilíbrio pode produzir uma boa ordenação média dos riscos, refletida na AUC, mas probabilidades e decisões por threshold menos estáveis.

4. A maior AUC não dominou as métricas clinicamente relevantes

Se o objetivo fosse apenas ranking estatístico por AUC, o ExtraTrees seria a escolha. Mas para um modelo clínico, é preciso olhar também para precision-recall, calibração e matriz de confusão. O ExtraTrees teve Average Precision inferior ao BernoulliNB e mais falsos negativos. Como a recorrência é a classe positiva de interesse, esta troca não é automaticamente aceitável.

Conclusão sobre árvores. O ExtraTrees deve ser reportado como melhor AUC nominal e como análise de sensibilidade. Contudo, para modelo principal, o BernoulliNB tuned é mais simples, mais fácil de defender e mais equilibrado no comportamento clínico observado.

Decisão final recomendada

Modelo principal: BernoulliNB tuned. Apesar de o ExtraTrees tuned ter a maior AUC nominal, o BernoulliNB tuned é a opção principal mais defensável para publicação: desempenho muito próximo, melhor comportamento em precision-recall, maior sensibilidade, melhor F1 e menor risco de sobreinterpretação num dataset pequeno.

Justificação metodológica

- A diferença ExtraTrees vs BernoulliNB é pequena em termos absolutos: 0.734 contra 0.726 de AUC LOOCV.
- O BernoulliNB tuned tem melhor Average Precision, relevante num problema com classe positiva minoritária.
- O ExtraTrees tuned tem melhor Brier score, mas pior sensibilidade, F1, balanced accuracy e NPV no threshold 0.50.
- Modelos de árvores podem ser úteis como análise exploratória, mas são mais difíceis de defender como modelo principal num n=151 sem validação externa.
- A decisão evita escolher exclusivamente pelo maior número observado e alinha-se com a lógica TRIPOD+AI/PROBAST+AI: transparência, avaliação interna honesta e cautela face ao risco de viés.

Papel de cada modelo no trabalho

- BernoulliNB tuned: modelo principal pré-operatório recomendado.
- ExtraTrees tuned: análise complementar/sensibilidade; melhor AUC nominal, mas com cautela quanto a estabilidade, interpretabilidade e comportamento clínico no threshold.
- GNB fixed: baseline conservador e interpretável, útil para demonstrar robustez da pipeline.

Blanking period

A variável blanking_period não deve entrar no modelo primário porque é pós-procedural e não responde ao objetivo clínico de prever risco antes da ablação. Deve ser apresentada apenas como análise de sensibilidade contextual.

Modelo	AUC sem blanking	AUC com blanking	Interpretação
GNB fixed	0.702	0.723	Aumenta moderadamente ao adicionar informação pós-procedural.
BernoulliNB tuned	0.726	0.684	Diminui; mostra que a variável não melhora todos os modelos.
ExtraTrees tuned	0.734	0.779	Aumenta bastante, reforçando que blanking é informação pós-procedural e não o objetivo primário.

Fonte: results_comp_modelos/final_options/v16_3_final_options_with_blanking_summary.csv.

Como escrever isto no artigo

Formulação sugerida:

O modelo principal pré-operatório selecionado foi o BernoulliNB com seleção ANOVA fold-local e hyperparameter tuning interno. Embora o ExtraTrees tenha obtido a maior AUC LOOCV nominal, a diferença face ao BernoulliNB foi pequena, e o BernoulliNB apresentou melhor desempenho em métricas complementares relevantes para a classe positiva, nomeadamente Average Precision, sensibilidade e F1 no threshold 0.50. O ExtraTrees foi, por isso, mantido como análise complementar de sensibilidade, enquanto o GNB fixed foi reportado como baseline conservador e interpretável.

Limitações a assumir

- A amostra é pequena: 151 doentes, com 52 recorrências.
- A ausência de validação externa impede afirmar generalização clínica robusta.
- Há falsos negativos relevantes em todos os modelos; isto deve ser assumido explicitamente.

- A AUC não descreve sozinha utilidade clínica; calibração, threshold e impacto de falsos negativos/falsos positivos devem ser discutidos.
- O modelo deve ser apresentado como estratificação de risco e prova de conceito, não como ferramenta autónoma de decisão clínica.

Enquadramento com literatura e risco de viés

A decisão é consistente com recomendações atuais para modelos preditivos clínicos baseados em IA: declarar claramente o objetivo, separar treino/validação/teste dentro da validação, evitar seleção de features usando o teste, reportar calibração/discriminação e discutir risco de viés e aplicabilidade.

- TRIPOD+AI recomenda reporte transparente de modelos preditivos com IA, incluindo participantes, preditores, outcome, validação e performance.
- PROBAST+AI enfatiza risco de viés em seleção de participantes, preditores, outcome e análise, especialmente com tuning e amostras pequenas.
- Trabalhos sobre calibração em modelos clínicos salientam que boa discriminação não garante probabilidades clinicamente calibradas.
- Literatura sobre high-dimensional low-sample-size data mostra que nenhum classificador domina em todos os cenários e que ruído, imbalance e distribuição das features mudam a performance relativa.

Conclusão final

A decisão final recomendada é usar o BernoulliNB tuned como modelo principal pré-operatório. O ExtraTrees tuned deve ser mostrado como análise complementar porque tem a maior AUC nominal, mas não deve substituir automaticamente o BernoulliNB como modelo principal sem validação externa. O GNB fixed deve permanecer como baseline. Esta estratégia é a mais honesta e defensável: mostra a melhor performance encontrada, mas evita sobreinterpretar diferenças pequenas num dataset limitado.

Referências úteis

1. Collins GS et al. TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. BMJ, 2024. <https://www.bmj.com/content/385/bmj-2023-078378>
2. PROBAST+AI: updated tool for assessing risk of bias and applicability in prediction model studies using artificial intelligence. BMJ, 2025. <https://www.bmj.com/content/388/bmj-2024-082505>
3. Van Calster B et al. Calibration: the Achilles heel of predictive analytics. BMC Medicine, 2019. <https://bmcmmedicine.biomedcentral.com/articles/10.1186/s12916-019-1466-7>
4. Geurts P, Ernst D, Wehenkel L. Extremely randomized trees. Machine Learning, 2006. <https://services.montefiore.uliege.be/stochastic/pubs/2006/GEW06a/>
5. Guo Y et al. Sample size and statistical power considerations in high-dimensionality data settings: a comparative study of classification algorithms. BMC Bioinformatics, 2010. <https://link.springer.com/article/10.1186/1471-2105-11-447>

6. Riley RD et al. Minimum sample size for developing a multivariable prediction model: PART II - binary and time-to-event outcomes. *Statistics in Medicine*, 2019.
<https://pubmed.ncbi.nlm.nih.gov/30357870/>